2 Testes para uma amostra

2.1 Teste Binomial

Seja X uma v.a. dicotômica $\{sucesso, \quad fracasso\}$. Assim, escrevemos $X \sim Bernoulli(p)$ e

$$X = \begin{cases} 1, & \text{se "sucesso"}, \quad \text{com probabilidade } p, \\ 0, & \text{se "fracasso"}, \quad \text{com probabilidade } 1-p. \end{cases}$$

Seja $X_1,\ X_2,\ \cdots,\ X_n$. Sabemos que $\widehat{p} = \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ é um "bom" estimador para o parâmetro (desconhecido) p. Considere os seguintes possíveis testes de hipótese para p:

$$H_0 : p = p_0 \quad \times \quad H_1 : \begin{cases} p \neq p_0 \\ p > p_0 \\ p < p_0 \end{cases},$$

onde p_0 é um valor específico, $0 < p_0 < 1$.

Pela propriedade dos estimadores de máxima verossimilhança (EMV), temos que $\widehat{p} \overset{a}{\sim} N(p, p(1-p)/n)$, para n grande. Usualmente usamos esta propriedade para confeccionar testes de hipóteses para a proporção p por aproximação da Binomial para a Normal. Por outro lado, temos que

$$S = \sum_{i=1}^{n} X_i \sim \ Binomial(n, p).$$

Assim, temos que $P(S = k) = \left(\begin{array}{c} n \\ k \end{array} \right) p^k (1-p)^{n-k}$, para $k = 0, 1, ..., n$, e $P(S \leq k) = \sum_{i=1}^{k} P(S = i)$, $P(S \geq k) = \sum_{i=k}^{n} P(S = i)$. Assim, podemos construir testes de hipóteses exatos usando S como nossa estatística de teste.

a. Para testar $H_1 : p > p_0$, rejeite H_0 a um nível de significância α se $S \geq b_\alpha$, onde b_α (valor crítico) é escolhido para fazer a probabilidade do erro tipo I igual a α, calculado da distribuição da estatística de teste sob H_0 (S_0). Porém, como a Binomial é uma v.a. discreta, não temos b_α para qualquer $0 < \alpha < 1$. Por exemplo, para $n = 8$ e $p_0 = 0.4$, temos que $\alpha = P(S_0 \geq 7) = 0.0085;\ b_\alpha = 7$ e $\alpha = P(S_0 \geq 6) = 0.0498;\ b_\alpha = 6$.

b. Para testar $H_1 : p < p_0$, rejeite H_0 a um nível de significância α se $S \leq b_\alpha$. Por exemplo, para $n = 8$ e $p_0 = 0.4$, temos que $\alpha = P(S_0 \leq 0) = 0.0168$; $b_\alpha = 0$ e $\alpha = P(S_0 \leq 1) = 0.1064$; $b_\alpha = 1$.

c. Para testar $H_1 : p \neq p_0$, rejeite H_0 a um nível de significância α se $S \geq b_{\alpha_1}$ ou $S \leq c_{\alpha_2}$, tal que $\alpha = \alpha_1 + \alpha_2$. Por exemplo, para $n = 8$ e $p_0 = 0.4$, se escolhemos $\alpha_1 = 0.0498$ e $\alpha_2 = 0.1064$, então $\alpha = 0.0498 + 0.1064 = 0.1562$ e rejeite H_0 se $S \leq 1$ ou $S \geq 6$. Mais detalhes, ver Hollander and Wolfe (2014), pág. 11.

Para grandes amostras, podemos substituir com sucesso o teste exato da Binomial usando a distribuição assintótica de $\overline{X}$ para a distribuição normal. Esta abordagem não será discutida aqui, pois é pressuposto ter sido vista em cursos anteriores de *Inferência Estatística Paramétrica*. Para maiores detalhes, ver Bussab and Morettin (2010), pág. 341; Conover (1999), pág. 124.

No R: binom.test{stats}

2.2 Estatísticas de Ordem e Função Distribuição

2.2.1 Função Quantil

Considere um experimento onde fixamos um cabo de aço de comprimento a em uma parede e exercemos um força em sua outra extremidade até que o cabo se rompa.
Questões de interesse:
→ Interesse na resistência à ruptura de um cabo (por ex.).
→ Força mediana para arrebentar o cabo.
→ Que porcentagem dos itens sobrevivem a uma pressão de 3 libras?
→ Qual é a força que é "sobrevivida" por 60% dos itens?

Definição 6. *O quantil de uma função distribuição acumulada (fda) de uma variável aleatória X contínua é um número real que divide a área sob a curva da fda em duas partes. Ou seja, o p-ésimo quantil da fda F_X de X é o valor de X, digamos X_p, tal que $100p\%$ dos valores de X na população são menores ou iguais a X_p, $0 < p < 1$.*

Observações:

- X_p é tal que $F_X(X_p) = P(X \leq X_p) = p$.
- $X_p \stackrel{d}{=} \int_{-\infty}^{X_p} f_X(x)dx = p$.
- Se F_X é estritamente crescente, $X_p = F_X^{-1} = Q_X(p)$ é solução única.

Nós chamamos $Q_X(p)$, $0 < p < 1$, como a *função quantil* da variável aleatória X.

Exemplo 2.1. $X \sim Exponencial(\lambda)$.

Neste caso, temos que
$f_X(x) = \lambda e^{-\lambda x}, x \geq 0, \lambda > 0$.

$F_X(x) = \int_{-\infty}^{x} \lambda e^{-\lambda z} dz = \frac{\lambda e^{-\lambda z}}{-\lambda}|_{z=0}^{x} = -e^{-\lambda z}|_{z=0}^{x} = -(e^{-\lambda x} - e^{-0}) = 1 - e^{-\lambda x}, x \geq 0$.

• *Análise se é estritamente crescente*
Primeira forma: $F'_X = f_X(x) = \lambda e^{-\lambda x} > 0, \forall x$.
Segunda forma: Suponha $x_1 < x_2$. *Então*

$$\begin{aligned} x_1 < x_2 &\iff \lambda x_1 < \lambda x_2 \ (\lambda > 0) \\ &\iff -\lambda x_1 > -\lambda x_2 \\ &\iff e^{-\lambda x_1} > e^{-\lambda x_2} \ (\textit{Exponencial é crescente}) \\ &\iff -e^{-\lambda x_1} < -e^{-\lambda x_2} \\ &\iff F_X(x_1) = 1 - e^{-\lambda x_1} < 1 - e^{-\lambda x_2} = F_X(x_2). \end{aligned}$$

• *Cálculo de* $Q_X(p)$*:*

Iguala $F_X(X_p) = p$ *e encontra* X_p.

$F_X = 1 - e^{-\lambda X_p} = p$

$1 - p = e^{-\lambda X_p}$

$ln(1-p) = -\lambda X_p$

$\therefore X_p = -\frac{1}{\lambda} ln(1-p).$

$\bullet S_X = [0, +\infty)$ *(suporte da v.a. X)*

$\bullet X_p$ *deve pertencer a* S_X

$\bullet Q_X(p) = \frac{-1}{\lambda} ln(1-p), 0 < p < 1.$

$X_p \in S_X$*? Como verificar.*

$0 < p < 1$

$\iff -1 < -p < 0$

$\iff 0 < 1 - p < 1$

$\iff ln(1-p) < 0$

$\iff \frac{1}{\lambda} ln(1-p) < 0$

$\iff X_p = -\frac{1}{\lambda} ln(1-p) > 0.$

Logo, X_p *pertence ao suporte de* X*.*

Definição 7. *(Definição Geral de Quantil):* $Q_X(p)$ *é o menor valor de* X *tal que* F_X *é maior ou igual a p. Isto é,*

$$Q_X(p) = F_X^-(p) = inf_x\{F_X(x) \geq p\}.$$

Teorema 1. *Se* X *é uma v.a. contínua com função quantil* Q_X*, temos que*

$$E(X) = \int_0^1 Q_X(p)dp \text{ e } E(X^2) = \int_0^1 Q_X^2(p)dp.$$

Teorema 2. *(Teorema da Probabilidade Total - PIT) Seja* X *uma v.a. com fda* F_X*. Se* F_X *é contínua, então*

$$Y = F_X(X) \sim U(0,1).$$

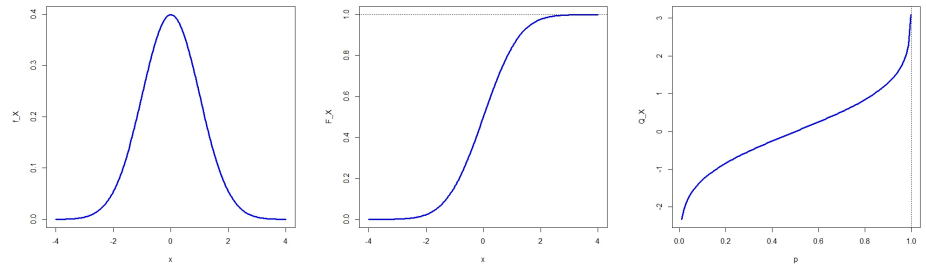


Figura 1: Gráficos da fdp, fda e função quantil de $X \sim Normal(0, 1)$ (esquerda para a direita).

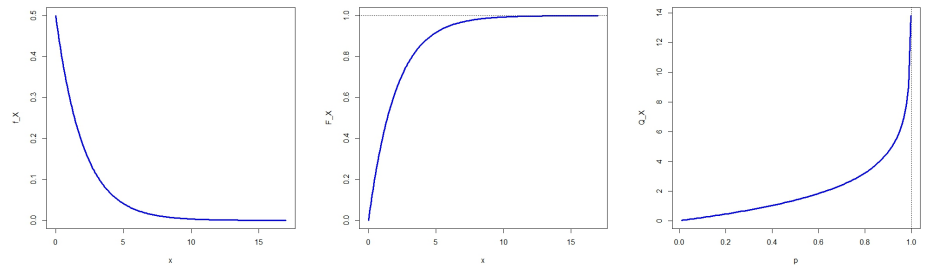


Figura 2: Gráficos da fdp, fda e função quantil de $X \sim Exp(0.5)$ (esquerda para a direita).

Prova: Ver Gibbons and Chakraborti (2003), pág. 42.

Exemplo 2.2. *Fazer para* $X \sim U(0, 1)$ *e* $X \sim Exp(\lambda)$.

Aplicação do PIT: O resultado é útil para geração de amostras aleatórias de uma v.a. contínua, usando o gerador de v.a. de uma $U(0, 1)$.

Algoritmo:
Dada uma v.a. X contínua.

i. Calcule a fda de X, $F_X(.)$.

ii. Calcule o quantil $X_p = F_X^{-1}(p)$.

iii. Gere uma a.a. U_1,...,U_n de $U \sim U(0, 1)$.

iv Calcule $X_i = F_X^{-1}(U_i)$, para $i = 1, ..., n$.

v. Portanto, X_1,...,X_n é uma a.a. de X.

Exemplo 2.3. *Mostrar para* $X \sim Exp(\lambda)$.

2.2.2 Estatísticas de Ordem da Amostra

Objetivo: Testar se um determinado conjunto de dados segue uma determinada distribuição.

Definição 8. *Dada uma amostra aleatória (aa)* $X_1,\ X_2,\ \cdots,\ X_n$ *de uma população com função densidade de probabilidade (fdp) de uma variável aleatória (v.a.)* X *contínua, então existe um único arranjo ordenado* $X_{(1)} < X_{(2)} < \cdots < X_{(n)}$ *onde* $X_{(i)}$ *denota o i-ésimo menor elemento da amostra. Definimos então* $X_{(r)}$ *como a r-ésima estatística de ordem da amostra.*

Outras notações: $\underset{\sim}{\mathbf{X}} = (X_1,\ X_2,\ \cdots,\ X_n)$ (Amostra) e $\left\{X_{(i)}\right\}_{i=1}^{n}$ (Estatísticas de Ordem da amostra $\underset{\sim}{\mathbf{X}}$).

Exemplo 2.4.

i. $X_{(n)}$*: Máximo amostral.*

ii. $X_{(1)}$*: Mínimo amostral.*

iii. $R = X_{(n)} - X_{(1)}$*: Amplitude amostral (medida de escala)*

iv. $\widetilde{X}$*: Mediana amostral (medida de tendência central), dada por*

$$\widetilde{X} = \begin{cases} X_{\left(\frac{n+1}{2}\right)}, & \text{se } n \text{ é ímpar;} \\ \\ \frac{X_{(n/2)} + X_{(n/2+1)}}{2}, & \text{se } n \text{ é par.} \end{cases}$$

v. $S = \frac{X_{(1)} + X_{(n)}}{2}$*: Semi-amplitude amostral (medida de tendência central)*

vi. Quartis, Decis, Percentis, ...

Definição 9. *Para uma a.a de X com fda F_X, a função distribuição empírica (fde), denotada por $F_n(x)$, é a proporção de valores amostrais menores ou iguais ao valor especificado x, para todo $x \in \mathbb{R}$. Isto é,*

$$F_n(x) = \frac{\textit{número de valores amostrais} \leq x}{n}.$$

Formalmente, temos que

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{(-\infty,x]}(X_i),$$

onde $\mathbb{1}_A(x)$ é a função indicadora, dada por

$$\mathbb{1}_A(t) = \begin{cases} 1, & \text{se } t \in A, \\ 0, & \text{caso contrário.} \end{cases}$$

Outra forma equivalente da função indicadora é da forma $\mathbb{1}_{(-\infty,x]}(X_i) = \mathbb{1}_{(X_i \leq x)}$.

A função $F_n(x)$ é popularmente chamada de "função escada" e seu gráfico de "gráfico de escada". Outra forma de escrever $F_n(x)$ é

$$F_n(x) = \begin{cases} 0, & \text{se } x < X_{(1)}, \\ 1/n, & \text{se } X_{(1)} \leq x < X_{(2)}, \\ 2/n, & \text{se } X_{(2)} \leq x < X_{(3)}, \\ \vdots & \vdots \\ k/n, & \text{se } X_{(k)} \leq x < X_{(k+1)}, \\ \vdots & \vdots \\ (n-1)/n, & \text{se } X_{(n-1)} \leq x < X_{(n)}, \\ 1, & \text{se } x \geq X_{(n)}. \end{cases}$$

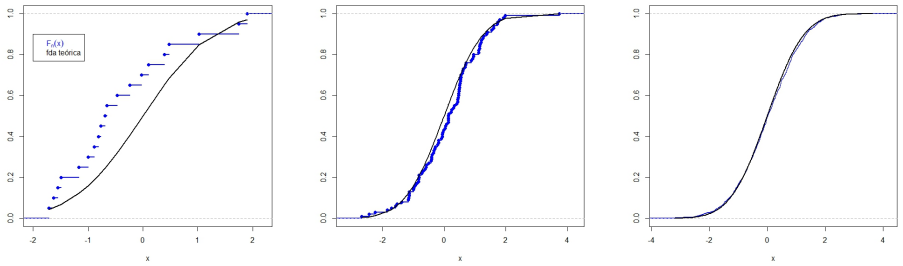
Propriedades

- $F_n(x)$ é uma variável aleatória.
- $F_n(x)$ é um estimador de $F_X(x)$, isto é, $F_n(x) = \widehat{F_X(x)}$.
- $F_n(x)$ é um estimador não-viesado de $F_X(x)$ e $Var(F_n(x)) \underset{\text{n}\to\infty}{\to} 0$.
- $T_n(x) = \sum_{i=1}^{n} \mathbb{1}_{(-\infty,x]}(X_i) \sim Binomial(n, F_X(x))$.

- (Teorema de Glivenko-Cantelli) Para qualquer x fixado, $F_n(x)$ é um estimador consistente de $F_X(x)$. Ou seja,

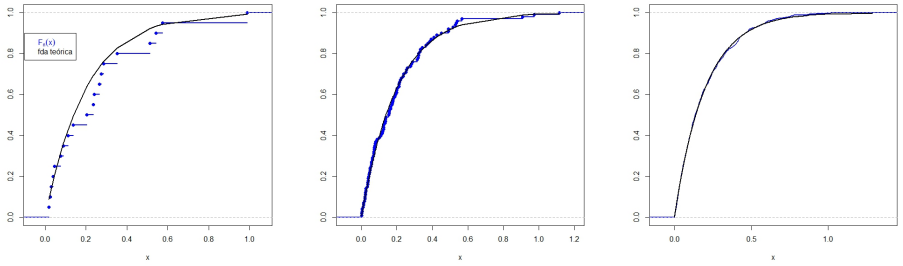
$$F_n(x) \underset{\text{n}\to\infty}{\overset{\text{q.c.}}{\to}} F_X(x).$$

A prova do Teorema de Glivenko-Cantelli pode ser encontrada em https://www.stat.purdue.edu/ jianzhan/STAT598Y/NOTES/slt07.pdf. As Figuras 3-4 apresentam empiricamente a convergência de F_n para a verdadeira função distribuição acumulada para a distribuição Normal e Exponencial.



(a) (b) (c)

Figura 3: Gráficos das funções distribuição empírica (F_n) e teórica (fda) de $X \sim Normal(0, 1)$: (a) $n = 20$, (b) $n = 100$, (c) $n = 1000$.



(a) (b) (c)

Figura 4: Gráficos das funções distribuição empírica (F_n) e teórica (fda) de $X \sim Exp(5)$: (a) $n = 20$, (b) $n = 100$, (c) $n = 1000$.

Definição 10. *Para uma a.a de X com fda F_X, a função quantil empírica, denotada por $Q_n(u)$, é dada por*

$$Q_n(u) = \begin{cases} X_{(1)}, & se\ 0 < u \leq 1/n, \\ X_{(2)}, & se\ 1/n < u \leq 2/n, \\ X_{(3)}, & se\ 2/n < u \leq 3/n, \\ \vdots & \vdots \\ X_{(k)}, & se\ (k-1)/n < u \leq k/n, \\ \vdots & \vdots \\ X_{(n-1)}, & se\ (n-2)/n < u \leq (n-1)/n, \\ X_{(n)}, & se\ (n-1)/n < u \leq 1. \end{cases}$$

Lista de exercícios 2.1. *Gere amostras das distribuições abaixo. Para cada amostra, construa 3 gráficos: o histograma de densidade mais a função densidade de probabilidade (caso contínuo), função distribuição (empírica e teórica) e função quantil (empírica e teórica). Para as variáveis discretas, fazer apenas gráfico de barras das frequências relativas ou histograma de densidade (mais a função de probabilidade) e função distribuição (empírica e teórica).*

a. $X \sim N(5, 2)$, *n=50.*

b. $X \sim N(5, 2)$, *n=200.*

c. $X \sim N(100, 1)$, *n=50.*

d. $X \sim exp(5)$, *n=50.*

e. $X \sim exp(1/5)$, *n=50.*

f. $X \sim exp(5)$, *n=200.*

g. $X \sim Poisson(5)$, *n=50.*

h. $X \sim Poisson(5)$, *n=100.*

OBS.: Entregar comandos e gráficos gerados. Usar R Markdown.

2.2.3 Distribuições de Estatísticas de Ordem

Teorema 3. *Seja X_1, X_2, ..., X_n uma amostra aleatória de uma v.a. X com fdp (ou f.p.) f_X e seja $\underset{\sim}{\mathbf{X}}_0 = (X_{(1)}, X_{(2)}, ..., X_{(n)})$ o vetor das n estatísticas de ordem. A distribuição de $\underset{\sim}{\mathbf{X}}_0$ é dada por*

$$f_{\underset{\sim}{\mathbf{X}}_0}(y_1, ..., y_n) = n! \prod_{i=1}^{n} f_X(y_i), \quad \text{para } y_1 < y_2 < \cdots < y_n.$$

Exemplo 2.5. *Se $X \sim N(\mu, \sigma^2)$, temos que*

$$f_{\underset{\sim}{\mathbf{X}}_0}(y_1, ..., y_n) = \frac{n!}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu)^2}, \quad \text{para } y_1 < y_2 < \cdots < y_n.$$

Teorema 4. *Seja X_1, X_2, ..., X_n uma amostra aleatória de uma v.a. contínua X. Para qualquer t fixo, a função distribuição acumulada da r-ésima estatística de ordem é dada por*

$$\begin{aligned} F_{X_{(r)}}(t) &= P(X_{(r)} \leq t) \\ &= \sum_{i=r}^{n} \binom{n}{i} F_X(t)^i \left[1 - F_X(t)\right]^{n-i}. \end{aligned} \tag{2}$$

Demonstração. Temos que $X_{(r)} \leq t \iff$ pelo menos r valores X_i são iguais ou menores que t $\iff T_n(t) = \sum_{i=1}^{n} \mathbb{1}(X_i \leq t) \geq r$.

Portanto, $P(X_{(r)} \leq t) = P(T_n(t) \geq r)$, o que conclui a prova. □

Teorema 5. *Seja X_1, X_2, ..., X_n uma amostra aleatória de uma v.a. contínua X com fdp f_X e fda F_X. A função densidade de probabilidade da r-ésima estatística de ordem é dada por*

$$f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!} F_X(x)^{r-1} \left[1 - F_X(x)\right]^{n-r} f_X(x). \tag{3}$$

Exemplo 2.6. *Fazer para $X_{(1)}$ e $X_{(n)}$.*

Corolário 1. *Para uma a.a. de tamanho n de $X \sim U(0,1)$, temos que $X_{(r)} \sim Beta(r, n-r+1)$.*

Observação: Se $X \sim Beta(\alpha, \beta)$, então $f_X(x) = \frac{1}{\beta(\alpha,\beta)} x^{\alpha-1}(1-x)^{\beta-1}, \quad 0 < x < 1; \alpha > 0, \beta > 0$, onde $\beta(\alpha, \beta) = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1}dx$ é a função beta.

Distribuição conjunta de duas estatísticas de ordem $\left(X_{(r)}, X_{(s)}\right)$, $1 \leq r < s \leq n$ (supomos $r < s$ sem perda de generalidade).

Teorema 6. *Seja X_1, X_2, ..., X_n uma amostra aleatória de uma v.a. contínua X com fdp f_X e fda F_X. A função densidade de probabilidade conjunta das estatísticas de ordem (r, s) é dada por*

$$f_{X_{(r)},X_{(s)}}(x, y) = \tag{4}$$
$$= C_{rs} F_X(x)^{r-1} \left[F_X(y) - F_X(x)\right]^{s-r-1} \left[1 - F_X(y)\right]^{n-s} f_X(x) f_X(y), \quad \textit{para } x < y.$$

onde $C_{rs} = \frac{n!}{(r-1)!(s-r-1)!(n-s)!}$.

Prova: Gibbons and Chakraborti (2003), pág. 48.

Exemplo: Distribuição conjunta de $\left(X_{(1)}, X_{(n)}\right)$:

$$f_{X_{(1)},X_{(n)}}(x, y) = n(n-1) \left[F_X(y) - F_X(x)\right]^{n-2} f_X(x) f_X(y), \quad \text{para } x < y.$$

Exemplo 2.7. *Distribuição da mediana amostral.*

Pra n ímpar, basta tomar $r = (n+1)/2$ e usar a expressão em (3). Para n par, temos que $\widetilde{X} = \frac{X_{(n/2)} + X_{(n/2+1)}}{2}$. Considere $V = X_{(n/2+1)}$. Assim, use a expressão em (4) e o método do Jacobiano para calcular a distribuição do vetor $(\widetilde{X}, V)$, integre em V para obter a marginal de $\widetilde{X}$. Assim, considerando $m = n/2$, temos que

$$f_{\widetilde{X}}(u) = \frac{(2m)!2}{[(m-1)!]^2} \int_u^{+\infty} F_X(2u - v)^{m-1} \left[1 - F_X(v)\right]^{m-1} f_X(2u - v) f_X(v) dv$$

Para maiores detalhes, ver Gibbons and Chakraborti (2003), pág. 50.

Exemplo 2.8. *Distribuição da amplitude amostral $R = X_{(n)} - X_{(1)}$. Considere $V = X_{(n)}$, use a expressão em (4) e o método do Jacobiano para calcular a distribuição do vetor (R, V), integre em V para obter a marginal de R. Obtemos que*

$$f_R(r) = n(n-1) \int_r^S [F_X(v) - F_X(v-r)]^{n-2} f_X(v-r) f_X(v) dv, \quad r > 0,$$

onde S é o limite superior do suporte de X. Para maiores detalhes, ver Gibbons and Chakraborti (2003), pág. 52.

Lista de exercícios 2.2. *Gibbons and Chakraborti (2003), Cap. 2: 6, 14, 24 e 25.*

2.3 Testes de hipóteses de bondade de ajuste

Objetivo: Testar se uma particular amostra vem de uma determinada distribuição especificada. Por exemplo, para uma variável categórica, existe diferença significativa entre as frequências observada e esperada? É razoável acreditar que a amostra tenha sido extraída de uma população com uma determinada distribuição (Normal, Exponencial, Uniforme, etc.)?

2.3.1 Teste de Qui-Quadrado para variáveis aleatórias categóricas ou discretas

Objetivo: Testar se as diferenças entre valores observados e esperados em cada célula de uma tabela de contingência são significantes.

Aqui supomos que tenhamos uma variável Y com m categorias, m finito. Poderia ser uma variável categórica (nominal) como "sexo", "raça", "estado civil", onde devemos pensar em uma distribuição Multinomial com m categorias. Ou poderia ser uma variável aleatória discreta, como "número de tentativas até obter um sucesso", "resultado do lançamento de um dado" ou "número de acidentes por dia em determinada cidade".

Seja $p_i = P(Y = a_i),\ i = 1, ..., m$, sendo que $\sum_{i=1}^{m} p_i = 1$. Considerando uma a.a. $Y_1, \cdots, Y_n$ de uma v.a. Y, temos que o valor esperado do número de observações na categoria i é dado por $E_i = n\, p_i,\ i = 1, ..., m$. Obviamente, $\sum_{i=1}^{m} E_i = \sum_{i=1}^{m} n\, p_i = n \sum_{i=1}^{m} p_i = n$.

Por outro lado, seja $O_i,\ i = 1, \cdots m$, a frequência observada da i-ésima categoria de Y (a_i), com $\sum_{i=1}^{m} O_i = n$. A Tabela 2 apresenta os dados das frequências observadas e esperadas das m categorias da variável Y relativas à amostra aleatória de tamanho n.

O teste de hipóteses considerado é:

H_0 : Os dados seguem a distribuição de probabilidade de Y;
H_1 : Os dados não seguem a distribuição de probabilidade de Y;

Tabela 2: Tabela de frequências observadas e esperadas.

Categoria/classe	1	2	$\cdots$	m	Total
Observado	O_1	O_2	$\cdots$	O_m	n
Esperado	E_1	E_2	$\cdots$	E_m	n

A estatística de teste, denominada *Estatística de Qui-Quadrado de Pearson*, é dada por

$$X^2 = \sum_{i=1}^{m} \frac{(E_i - O_i)^2}{E_i}.$$

Para n grande, temos que $X^2 \overset{a}{\sim} \chi^2_{(g)}$, com $g = m - 1$, onde $\overset{a}{\sim}$ significa aproximadamente. O p-valor é dado por $p - valor = P(\chi^2_{(g)} \geq x^2)$, onde x^2 é o valor observado da estatística X^2 (Figura 5).

Uma desvantagem do teste Qui-quadrado é que ele somente pode ser usado para grandes amostras. Por outro lado, pode ser usado em variáveis categóricas.

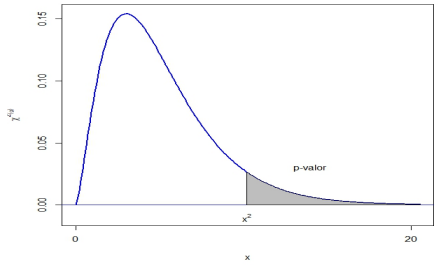


Figura 5: Representação do p-valor para o teste Qui-quadrado.

Exemplo 2.9. *(Siegel and Castellan, Jr. (2006), pág. 66). O exemplo trata de resultados de corridas de cavalos em um hipódromo com 8 posições de largada. Foram ao todo 144 corridas, distribuídas conforme a Tabela 3.*

Seja Y_i raia "vencedora" da i-ésima corrida, $i = 1, ..., 144$. Considere as hipóteses:

H_0 : *Não existe relação entre posição de largada e número de vitórias*
H_1 : *Existe relação entre posição de largada e número de vitórias*

De forma mais formal,

$$H_0 : p_i = 1/8,\ i = 1, ..., 8.$$
$$H_1 : p_i \neq 1/8,\ \textit{para pelo menos um } i \neq j.$$

A estatística de teste foi de $x^2 = 16.3$. *Assim, o p-valor é* $P(\chi^2_{(7)} \geq 16.3) = 0.022$. *Portanto, rejeitamos a hipótese nula, a um nível de significância de* $\alpha = 5\%$. *Portanto, o número de vitórias tem relação com a posição de largada.*

Tabela 3: Vitórias obtidas em uma pista circular para cavalos em 8 posições.

Categoria/classe	1	2	3	4	5	6	7	8	Total
Observado	29	19	18	25	17	10	15	11	144
Esperado	18	18	18	18	18	18	18	18	144

Restrições ao uso do teste qui-quadrado:

- Quando os graus de liberdade (g.l) forem iguais a 1 (m=2 classes), cada frequência esperada deve ser pelo menos 5.
- Quando $g.l. > 1$, o teste não deve ser aplicado se mais que 20% das células (categorias) possuem frequências esperadas menores que 5 ou se qualquer frequência esperada é menor que 1. Alternativa: agrupar categorias adjacentes ou "similares".

Bondade de ajuste com estimação de parâmetros

Exemplo 2.10. *(Sprent and Smeeton (2007), pág. 376) Uma fábrica possui 220 empregados. A Tabela 4 apresenta a frequência do número de acidentes sofridos pelos empregados ao longo de um ano. Podemos supor que o número de acidentes por empregado segue uma distribuição de Poisson com parâmetro* λ *desconhecido. Temos as hipóteses:*

H_0 : *Os dados seguem uma distribuição de Poisson.*
H_1 : *Os dados não seguem uma distribuição de Poisson.*

Algumas dificuldades surgem:

- *A distribuição de Poisson assume infinitos valores (inteiros não-negativos).*
- *Estimação do parâmetro λ.*
- *Possivelmente possui alguns valores esperados pequenos.*

... desenvolver.

Observação: O problema de estimar parâmetro λ reduz o número de graus de liberdade. A distribuição de Poisson supõe que o número de ocorrências é aleatório. Talvez não seja o caso aqui (se uma mesma pessoa sofre um acidente, a probabilidade dela sofrer outro deve alterar). Tentar uma distribuição Binomial Negativa.

Tabela 4: Número de acidentes por pessoas em um ano.

Número de acidentes	0	1	2	3	4	5	≥ 6
Número de pessoas	181	9	4	10	7	4	5

Exemplo 2.11. *(Gibbons and Chakraborti (2003), Ex. 2.1, pág. 108) Um engenheiro de controle de qualidade toma 50 amostras de tamanho 13 e anota o número de defeitos em cada amostra (Tabela 5). Faça testes de bondade de ajuste para as distribuições Binomial e Poisson, a um nível de significância de 5%.*

Tabela 5: Número de defeitos em amostras de tamanho 13.

Número de defeitos	0	1	2	3	4	5	≥ 6
Frequência	10	24	10	4	1	1	0

Lista de exercícios 2.3.

- *Sprent and Smeeton (2007), Cap. 4: 14.*
- *Gibbons and Chakraborti (2003), Cap. 4: 1, 2, 21, 25.*

2.3.2 Estatísticas do tipo Kolmogorov-Smirnov para distribuições completamente especificadas

Seja $X_1, X_2, \cdots, X_n$ uma a.a. de uma função distribuição acumulada desconhecida, denotada por $F(\cdot)$. Queremos testar se os dados vieram de uma determinada distribuição com fda F_X. A estatística de Kolmogorov-Smirnov (K-S), baseada nos trabalhos de Kolmogorov (1933, 1941) e Smirnov (1939, 1948), é calculada a partir da diferença entre as funções distribuição empírica e teórica. Relembremos que a função distribuição empírica $F_n(x)$ converge em probabilidade para $F_X(x)$, pelo Teorema de Glivenko-Cantelli. Assim, para n grande, a diferença, em módulo, entre as funções distribuição verdadeira e empírica, $|F_n(x) - F_X(x)|$, deveria ser pequena para todos os valores de x. Logo, temos a estatística

$$D_n = \sup_x |F_n(x) - F_X(x)|. \tag{5}$$

Podemos definir também as estatísticas de testes unilaterais como

$$D_n^+ = \sup_x [F_n(x) - F_X(x)] \quad D_n^- = \sup_x [F_X(x) - F_n(x)]. \tag{6}$$

Gibbons and Chakraborti (2003) mostram que

$$D_n^+ = max \left\{ \underset{1 \leq i \leq n}{max} \left[\frac{i}{n} - F_X(X_{(i)}) \right], 0 \right\}.$$

Similarmente, temos que

$$D_n^- = max \left\{ \underset{1 \leq i \leq n}{max} \left[F_X(X_{(i)}) - \frac{i-1}{n} \right], 0 \right\},$$

$$D_n = max \left\{ \underset{1 \leq i \leq n}{max} \left[\frac{i}{n} - F_X(X_{(i)}) \right], \underset{1 \leq i \leq n}{max} \left[F_X(X_{(i)}) - \frac{i-1}{n} \right], 0 \right\}.$$

Assim, as estatísticas de teste K-S dependem apenas das variáveis aleatórias $F_X(X_{(i)})$, que são as estatísticas de ordem de uma distribuição $U(0,1)$

(devido ao teorema PIT), quando F_X é contínua. Note que a estatística K-S independe da fda original F_X. O teste de Kolmogorov-Smirnov é denominado de "livre de distribuição" porque o procedimento não depende de qual é a distribuição em estudo, desde que seja completamente especificada em H_0 e F_X seja contínua. A derivação da distribuição de probabilidade de D_n (exata) é tediosa e pode ser encontrada no Teorema 3.2 de Gibbons and Chakraborti (2003), pág. 114.

Para grandes amostras, Kolmogorov (1933) apresenta uma distribuição limite para D_n, dada pelo teorema abaixo.

Teorema 7. *Se F_X é contínua, então para todo $d > 0$,* $\lim_{n\to\infty} P\left(D_n \leq d/\sqrt{n}\right) = L(d)$, *onde* $L(d) = 1 - 2\sum_{i=1}^{\infty}(-1)^{i-1}e^{-2i^2d^2}$.

Smirnov (1948) tabulou a função $L(d)$. A Tabela 6 traz alguns valores críticos.

Tabela 6: Valores críticos de D_n.

$P\left(D_n > d_\alpha/\sqrt{n}\right)$	0.20	0.15	0.10	0.05	0.02	0.01
d_α	1.07	1.14	1.22	1.36	1.52	1.63

A Tabela F em Siegel and Castellan, Jr. (2006) apresenta valores críticos exatos de D_n para $n \leq 35$ e níveis de significância de 20%, 15%, 10%, 5% e 1% do teste bilateral. A Tabela A13 em Conover (1999) apresenta valores críticos exatos de D_n para $n \leq 40$ e níveis de significância de 20%, 10%, 5%, 2% e 1% para testes bilaterais. Tabela I em Gibbons and Chakraborti (2003) apresenta valores críticos exatos de D_n para $n \leq 20$ e níveis de significância de 20%, 10%, 5%, 2% e 1% para testes bilaterais. Para testes unilaterais, os valores críticos são os mesmos considerando $\alpha^* = \alpha/2$ do teste bilateral. Todas as tabelas apresentam na última linha os valores críticos baseando na aproximação assintótica (Teorema 7).

Gibbons and Chakraborti (2003) apresentam também resultados para a distribuição assintótica de D_n^+.

Teorema 8. *Se F_X é contínua, então para todo $d \geq 0$,*

$$\lim_{n\to\infty} P\left(D_n^+ \leq d/\sqrt{n}\right) = 1 - e^{-2d^2}.$$

Corolário 2. *Se F_X é contínua, então para todo $d \geq 0$,*

$$V = 4nD_n^{+^2} \underset{n\to\infty}{\overset{D}{\to}} \chi^2_{(2)}.$$

Bandas de confiança para $F_X(x)$ podem ser construídas usando $F_n(x)$ e quantis da distribuição de D_n. Ver Conover (1999), pág. 438 ou Gibbons and Chakraborti (2003), pág. 124.

No R: ks.test{stats}

Aplicações:

Seja $X_1, X_2, \cdots, X_n$ uma a.a. de uma função distribuição acumulada desconhecida, denotada por F_X. Desejamos testar (H_0) se os dados vieram de uma determinada distribuição, completamente especificada, digamos F_0, contínua.

No teste bilateral, desejamos testar

$$H_0 : F_X(x) = F_0(x), \text{ para todo } x \in \mathbb{R}.$$
$$H_1 : F_X(x) \neq F_0(x), \text{ para algum } x.$$

Rejeitamos H_0 ao nível de significância α se $D_n > d_{n,\alpha}$, onde $d_{n,\alpha}$ é o valor crítico da estatística K-S (Tabela F em Siegel and Castellan, Jr. (2006) ou Tabela A13 em Conover (1999)). Os testes unilaterais, embora possam ser construídos e testados, é de pouca aplicação prática para casos de uma amostra e não será abordado aqui neste capítulo. Retornaremos com eles no Capítulo 3 (Testes para duas amostras independentes).

Exemplo 2.12. *Teste se os dados da Tabela 7 seguem uma distribuição Uniforme no intervalo* $(0, 1)$.

Tabela 7: Exemplo 1 (Conover, 1999), pag. 433.

0.621	0.503	0.203	0.477	0.710	0.581	0.329	0.480	0.554	0.382

Exemplo 2.13. *(Sprent and Smeeton, 2007) Suponha que pedaços de fios com 6 cm de comprimento estejam presos em cada extremidade e uma força seja aplicada até que se quebre. Se cada fio quebrar no ponto mais fraco e*

é provável que isso ocorra em qualquer lugar ao longo de seu comprimento, os pontos de ruptura serão distribuídos uniformemente ao longo do intervalo (0, 6), onde a distância até a ruptura é medida em centímetros a partir da braçadeira esquerda. Teste se os dados seguem uma distribuição Uniforme no intervalo $(0, 6)$.

Tabela 8: Exemplo 4.2 (Sprent and Smeeton, 2007), pág. 86.

0.6	0.8	1.1	1.2	1.4	1.7	1.8	1.9	2.2	2.4
2.5	2.9	3.1	3.4	3.4	3.9	4.4	4.9	5.2	5.9

Exemplo 2.14. *Teste se a raiz quadrada dos dados da Tabela 9 segue uma distribuição Uniforme no intervalo* $(0, 1)$.

Tabela 9: Exemplo 4.1 (Gibbons and Chakraborti, 2003), pág. 121.

0.0123	0.1039	0.1954	0.2621	0.2802
0.3217	0.3645	0.3919	0.4240	0.4814
0.5139	0.5846	0.6275	0.6541	0.6889
0.7621	0.8320	0.8871	0.9249	0.9634

2.3.3 Estatísticas do tipo Anderson-Darling para distribuições completamente especificadas

A medida de bondade de ajuste de Anderson and Darling (1954) baseada na função de distribuição empírica é definida por

$$W_n^2 = n \int_{-\infty}^{+\infty} [F_n(x) - F_X(x)]^2 \psi(F_X(x)) f_X(x) dx.$$

onde $\psi(F_X(x))$ é uma função peso.

Seja $X_1, X_2, \cdots, X_n$ uma a.a. de uma função distribuição acumulada desconhecida, denotada por $F(\cdot)$. Queremos testar se os dados vieram de uma determinada distribuição com fda F_X. O teste de Anderson-Darling (A-D) é uma modificação do teste de Cramer-von Mises, diferindo "apenas" na

função peso utilizada. A estatística de teste (Anderson and Darling, 1954) é dada por

$$W_n^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)[\log U_i(1-U_{n-i+1})],\ U_i = F_X(X_{(i)}).$$

Uma desvantagem da estatística A-D é que valores críticos não são disponíveis para pequenas amostras (Anderson and Darling, 1954). A distribuição assintótica é dada, porém, envolvendo séries infinitas envolvendo integrais. Lewis (1961) apresenta uma forma equivalente da estatística W_n^2 e calcula valores críticos da estatística para pequenas amostras. Marsaglia and Marsaglia (2004) propõe um método para avaliar a distribuição assintótica com grande acurácia, que é a base para a função criada no R.

No R: ad.test{goftest}.

2.3.4 Testes de bondade de ajuste para famílias de distribuições

Os testes desenvolvidos na Seção 2.3.2 são aplicados para distribuições completamente especificadas. Por exemplo, os dados vieram de $N(\mu_0, \sigma_0^2)$ ou $Exp(\lambda_0)$? Porém, em muitas situações, não sabemos quem é o parâmetro específico $\boldsymbol{\theta}_0$. Esse é o caso em problemas de Inferência Paramétrica, como testes de hipóteses e estimação de parâmetros. Tem-se a a.a. $X_1, X_2, ..., X_n$ de $X \sim F_X(\boldsymbol{\theta})$, onde o parâmetro $\boldsymbol{\theta}$ é desconhecido. Apresentaremos a seguir testes de bondade de ajuste para a distribuição Normal e para a Exponencial.

Inicialmente, definimos os coeficientes de assimetria ($\sqrt{\beta_1}$) e curtose (β_2) de uma variável aleatória X como

$$\sqrt{\beta_1} = \frac{E\left([X-\mu]^3\right)}{\sigma^3} \quad \text{e} \quad \beta_2 = \frac{E\left([X-\mu]^4\right)}{\sigma^4},$$

onde $\mu = E(X)$ e $\sigma^2 = Var(X)$. Para a distribuição Normal, temos que $\sqrt{\beta_1} = 0$ e $\beta_2 = 3$. Seus respectivos amostrais são dados por

$$\sqrt{b_1} = \frac{m_3}{m_2^{3/2}} \quad \text{e} \quad b_2 = \frac{m_4}{m_2^2},$$

onde $m_k = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^k$ é o k-ésimo momento amostral.

Testes para Normalidade

Seja $X_1, X_2, ..., X_n$ uma a.a. de $X \sim F(\boldsymbol{\theta})$. Desejamos testar

H_0 : Os dados seguem uma distribuição Normal, com média e variância desconhecidas.
H_1 : Os dados não seguem uma distribuição Normal.

i. Teste de Lilliefors

Sejam $\overline{X} = \sum_{i=1}^{n} X_i/n$ a média amostral e $S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2}$ o desvio-padrão amostral. Seja

$$Z_i = \frac{X_i - \overline{X}}{S}, \quad i = 1, ..., n.$$

O método de Lilliefors (1967, 1969) consiste em construir a estatística K-S e realizar o teste de hipóteses para a a.a. $Z_1, Z_2, ..., Z_n$. O autor usou simulação de Monte Carlo para desenvolver uma tabela K-S de valores críticos (Tabela A14 em Conover (1999), Tabela O em Gibbons and Chakraborti (2003)).

Uma ideia seria simplesmente testar que $Z_i \sim t_{n-1},\ i = 1, ..., n$.

No R: lillie.test{nortest}

ii. Teste de Shapiro-Wilk

Seja $D = \sum_{i=1}^{n}(X_i - \overline{X})^2 = (n-1)S^2$ e considere as n estatísticas de ordem $X_{(i)},\ i = 1, ..., n$. Usando a Tabela A16 (Conover, 1999), obtenha os k coeficientes do teste de Shapiro-Wilk (S-W) a_1,..., a_k (baseados nos valores esperados e covariâncias das estatísticas de ordem de uma a.a. de tamanho n de uma normal padrão), onde k é aproximadamente $n/2$. A estatística de S-W (Shapiro and Wilk, 1965) é dada por

$$W = \frac{1}{D}\left[\sum_{i=1}^{k} a_i \left(X_{(n-i+1)} - X_{(i)}\right)\right]^2.$$

Observações: A estatística original envolve $\sum_{i=1}^{n} a_i X_{(i)}$ no numerador. Porém, Shapiro and Wilk (1965) mostram que $-a_i = a_{n-i+1}$. Logo,

$\sum_{i=1}^{n} a_i X_{(i)} = \sum_{i=1}^{k} a_i \left(X_{(n-i+1)} - X_{(i)}\right)$. Sob H_0, a distribuição de W depende apenas do tamanho da amostra n. O valor mínimo de W é $na_1^2/(n-1)$ e o máximo é 1. A distribuição de W é obtida apenas de forma aproximada. Royston (1982) propõe uma extensão do teste para grandes amostras, que é utilizado na função do R (R Core Team, 2019).

No R: shapiro.test{stats}

iii Teste de D'Agostino-Pearson

A ideia é realizar testes para assimetria $H_0 : \sqrt{\beta_1} = 0$ e para curtose $H_0 : \beta_2 = 3$.

D'Agostino and Pearson (1973) sugerem utilizar a estatística

$$K^2 = X^2(\sqrt{b_1}) + X^2(b_2) \overset{\text{a}}{\sim} \chi^2_{(2)},$$

onde $X(a) = \delta \sinh^{-1}(a/\lambda)$ (denominado de desvio normal padronizado). As estatísticas $X^2(\sqrt{b_1})$ e $X^2(b_2)$ são aproximações normais para $\sqrt{b_1}$ e b_2, respectivamente, podendo ser obtidas, por exemplo, em Sheskin (2000) (Eq. 4.8 e 5.7) ou em D'Agostino et al. (1990).

No R: dagostino.pearson.test, disponível em https://stat.ethz.ch/pipermail/r-help/2004-August/056749.html.

iv Teste baseados na medida de Anderson-Darling

Quando $\psi(p) = \frac{1}{p(1-p)}$, temos a estatística de teste de Anderson-Darling

$$A^2 = -n - \frac{1}{n}\sum_{i=1}^{n}[2i-1]log[p_{(i)}(1-p_{(n-i+1)})],$$

onde $p_{(i)} = \Phi((x_{(i)} - \widehat{\mu})/\widehat{\sigma}) = \Phi((x_{(i)} - \overline{x})/s)$.

No R: ad.test{nortest}

Quando $\psi(p) = 1$, temos a estatística de Crámer-von Mises, definida por

$$W^2 = \frac{1}{12n} + \sum_{i=1}^{n}\left(p_{(i)} - \frac{2i-1}{2n}\right)^2.$$

No R: cvm.test{nortest}

Razali and Wah (2011) comparam, via estudos de simulação, testes de hipóteses para normalidade baseados nas estatísticas K-S, S-W e A-D e concluem que o teste de Shapiro-Wilk é o mais poderoso teste de normalidade, corroborando os achados de Mendes and Pala (2003) e Keskin (2006). Por outro lado, como pode ser visto em Sheskin (2000), autores como D'Agostino et al. (1990) e Zar (1999) argumentam que o teste de D'Agostino-Pearson é um dois mais poderosos, em comparação com estatísticas tipo K-S e Qui-quadrado de bondade de ajuste. Outros testes podem ser vistos em Thode Jr. (2002), Seção 5.1, dentre outros.

Teste de Lilliefors para a distribuição Exponencial

Seja $X_1, X_2, ..., X_n$ uma a.a. de $X \sim F(\boldsymbol{\theta})$. Desejamos testar

H_0 : Os dados seguem uma distribuição Exponencial, com parâmetro desconhecido.
H_1 : Os dados não seguem uma distribuição Exponencial.

Sabemos que se $X \sim Exp(\lambda)$, sua fdp é dada por $f_X(x) = \frac{1}{\lambda}e^{-x/\lambda}$, $x \geq 0$, $\lambda > 0$. Assim, X é da família de escala, ou seja, se $Z = X/\lambda \sim Exp(1)$. Assim, como $\overline{X}$ é o estimador de λ, considere então $Z_i = X_i/\overline{X}$, $i = 1, ..., n$. Assim, realizamos o teste aplicando a estatística K-S para $Z_1, ..., Z_n$ vinda de uma $Exp(1)$. Quantis exatos são dados na Tabela A15 (Conover, 1999).

Exemplos: Notas de aula.

Lista de exercícios 2.4.

- *Conover (1999), Cap. 6, pág. 454-455: 1 a 5.*
- *Gibbons and Chakraborti (2003), Cap. 4: 18, 19, 26.*
- *Sprent and Smeeton (2007), Cap. 4: 1 a 4.*

2.4 Testes de hipóteses de simetria

Seja $X_1, X_2, ..., X_n$ uma a.a. de com fdp f_X e fda $F_X(x) = F(x - \theta)$, $F(0) = 1/2$, onde $\theta \in \mathbb{R}$ é a mediana (única), média $\mu \in \mathbb{R}$ e variância $\sigma^2 > 0$. O

coeficiente de assimetria amostral é definido por

$$b_1 = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^3}{[\sum_{i=1}^{n}(X_i - \overline{X})^2]^{3/2}}.$$

As estatísticas de testes envolvem a variância amostral S^2 e seu respectivo erro-padrão amostral S, a média amostral $\overline{X}$ e a mediana amostral $\widetilde{X}$.

Se a distribuição F_X é simétrica em torno de θ, então $Z = X - \theta$, $F_Z(z) = P(Z \leq z) = P(Z \geq -z) = 1 - F_Z(-z)$. Assim os testes de hipóteses para simetria são da forma

$$\begin{array}{l} H_0 : F(x-\theta) = 1 - F(\theta - x), \quad \forall x \in \mathbb{R}. \\ H_1 : F(x-\theta) \neq 1 - F(\theta - x), \quad \text{para algum } x. \end{array} \tag{7}$$

Uma forma equivalente seria

$$\begin{array}{l} H_0 : f(\theta-x) = f(\theta + x), \quad \forall x \in \mathbb{R}. \\ H_1 : f(\theta-x) \neq f(\theta + x), \quad \text{para algum } x. \end{array} \tag{8}$$

Assim, seguem alguns testes para simetria.

i. (Cabilio and Masaro, 1996) Considere a medida de assimetria $\gamma_1(F) = \frac{\mu - \theta}{\sigma}$ dada por Yule (1944). Gastwirth (1971) propõe um teste baseado na versão amostral $\frac{\overline{X} - \widetilde{X}}{S}$. Cabilio and Masaro (1996) mostram que, sob certas condições,

$$\sqrt{n}[\overline{X} - \widetilde{X} - (\mu - \theta)] \underset{\text{n}\to\infty}{\overset{\text{D}}{\to}} N(0, \sigma^2(\gamma_1, F)),$$

onde $\sigma^2(\gamma_1, F) = \sigma^2 + \frac{1}{4f_X^2(\theta)} - \frac{1}{f_X(\theta)}\left[\mu - 2\int_{-\infty}^{\theta} x f_X(x)dx\right]$. De outra forma, podemos escrever

$$\sigma_*^2(\gamma_1, F) = \frac{\sigma^2(\gamma_1, F)}{\sigma^2} = 1 + \frac{1}{4\sigma^2 f_X^2(\theta)} - \frac{1}{\sigma f_X(\theta)}\left[\mu - 2\int_{-\infty}^{\theta} x f_X(x)dx\right].$$

Assim, temos que

$$\frac{\overline{X} - \widetilde{X} - (\mu - \theta)}{\sigma/\sqrt{n}} \underset{\text{n}\to\infty}{\overset{\text{D}}{\to}} N(0, \sigma_*^2(\gamma_1, F)).$$

Se $\mu = \theta$, sob as mesmas condições iniciais, tem-se que

$$\sigma_0^2(F) = 1 + \frac{1}{4\sigma^2 f_X^2(0)} - \frac{1}{\sigma f_X(0)} E\left|\frac{X-\mu}{\sigma}\right|.$$

Para distribuições unimodais, $0.25 \leq \sigma_0^2(F) \leq 1$, sendo igual a 0.5708 para a Normal padrão. Para distribuições da família de locação-escala, sendo $Z = \frac{X-\mu}{\sigma}$, então $f_X(x) = \frac{1}{\sigma} f_Z\left(\frac{x-\mu}{\sigma}\right)$ ou de outra forma, $\sigma f_X(x) = f_Z\left(\frac{x-\mu}{\sigma}\right)$. Assim, temos que $\sigma f_X(\theta) = \sigma f_X(\mu) = f_Z(0)$. Além disso, $E\left|\frac{X-\mu}{\sigma}\right| = E|Z|$. Logo, temos que

$$S_K = \frac{\overline{X} - \widetilde{X}}{S/\sqrt{n}} \underset{\text{n}\to\infty}{\overset{\text{D}}{\to}} N(0, \sigma_0^2(F)).$$

Cabilio and Masaro (1996) encontram percentis da distribuição de S_K para algumas distribuições F_X, encontrando o valor de $\sigma_0^2(F)$ para cada exemplo. Porém, isto seria irrealístico em dados reais, pois não sabemos qual é a distribuição de origem dos dados. Os autores argumentam que o valor de $\sigma_0^2(F) = 0.570796$ da Normal poderia ser usado para os testes, esta funcionando como uma distribuição de "calibração".

Usando a hipótese adicional de continuidade de f_X na vizinhança de 0, Cabilio and Masaro (1996) encontram um estimador consistente de $\sigma^2(\gamma_1, F)$, dado por

$$S^2(\gamma_1, F_n) = S^2 + \frac{1}{4f_n^2(m)} - \frac{d_{\overline{X}}}{f_n(m)},$$

onde $d_{\overline{X}} = \frac{1}{n}\sum_{i=1}^n |X_i - \overline{X}|$ e $f_n(m) = \frac{1}{2n^{4/5}} \max\left\{1, \sum_{i=1}^n \mathbb{1}_{[m-n^{-1/5}, m+n^{-1/5}]}(X_i)\right\}$. Assim, para testar (7), sob H_0, temos que $\mu - \theta = 0$ e usamos a estatística de teste

$$S_K^* = \frac{\overline{X} - \widetilde{X}}{S(\gamma_1, F_n)/\sqrt{n}} \overset{\text{a}}{\sim} N(0,1).$$

- (Mira, 1999) Considere a medida de assimetria $\gamma_1(F) = 2(\mu - \theta)$. Bonferroni (1933) provou que

$$\sqrt{n}[\widehat{\gamma}_1(F) - \gamma_1(F)] \underset{\text{n}\to\infty}{\overset{\text{D}}{\to}} N(0, \sigma^2(\gamma_1, F)),$$

onde $\widehat{\gamma}_1(F) = 2(\overline{X} - \widetilde{X})$, $\sigma^2(\gamma_1, F) = 4\sigma^2 + \frac{1}{f_X(\theta)^2} - \frac{4}{f_X(\theta)} S_\theta$ e $S_\theta = \mu - 2E(X\mathbb{1}_{(X \leq \theta)})$. Mira (1999) encontra um estimador consistente de $\sigma^2(\gamma_1, F)$, dado por

$$S_c^2(\gamma_1, F_n) = 4S^2 + D_{n,c}^2 - 4D_{n,c}S_n,$$

com $S_n = \overline{X} - \frac{2}{n}\sum_{i=1}^{n} \mathbb{1}_{(X_i \leq \widetilde{X})}$ e $D_{n,c} = \frac{n^{1/5}}{c}\left(X_{([n/2+cn^{4/5}])} - X_{([n/2+1-cn^{4/5}])}\right)$, $c = 0.5$ (caso normal) e $[a]$ é a função "maior inteiro", representando o menor inteiro menor ou igual a a. Assim, para testar (7), sob H_0, temos que $\gamma_1(F) = 0$ e usamos a estatística de teste

$$Z = \frac{2(\overline{X} - \widetilde{X})}{S_c(\gamma_1, F_n)/\sqrt{n}} \overset{\text{a}}{\sim} N(0, 1).$$

- (Miao et al., 2006) A proposta dos autores é propor um versão "robustificada" da estatística de teste de Cabilio and Masaro (1996), usando a estatística

$$T = \frac{\overline{X} - \widetilde{X}}{J},$$

onde $J = \sqrt{\frac{\pi}{2}} D$, com $D = \frac{1}{n}\sum_{i=1}^{n} |X_i - \widetilde{X}|$. Considerando $\lambda = \mu - \theta$, Miao et al. (2006) mostram que

$$\sqrt{n}\left[T - \frac{\lambda}{\sqrt{\frac{\pi}{2}\tau}}\right] \underset{\text{n}\to\infty}{\overset{\text{D}}{\to}} N(0, \sigma_T^2),$$

onde

$$\begin{aligned} \sigma_T^2 &= \frac{2}{\pi\tau^2}\left(\sigma^2 + \frac{1}{4f_X^2(\theta)} - \frac{\tau}{f_X(\theta)} + \frac{\lambda^2(\sigma^2 + \lambda^2)}{\tau^2}\right. \\ &\quad \left. -\lambda^2 - \frac{2\lambda}{\tau}[\sigma^2 - 2\eta + 2\mu\gamma - \theta\tau] + \frac{\lambda^2}{\tau f_X(\theta)}\right), \end{aligned}$$

$\tau = \int_{-\infty}^{\theta} x^2 f_X(x)dx$ e $\gamma = \int_{-\infty}^{\theta} x f_X(x)dx$.
Sob H_0, isto é, a distribuição é simétrica, $\lambda = \mu - \theta = 0$, tem-se que $\sigma_{T_0}^2 = \frac{2}{\pi\tau^2}\left[\sigma^2 + \frac{1}{4f_X^2(\theta)} - \frac{\tau}{f_X(\theta)}\right]$. Para aplicação, aproxima-se $\sigma_T^2 = 0.5708$. Assim, temos que

$$Z = \frac{T}{\sqrt{0.5708/n}} \overset{\text{a}}{\sim} N(0, 1).$$

No R: symmetry.test{lawstat}.

Outro teste de hipóteses para simetria é baseado nas triplas da amostra (X_i, X_j, X_k) (Randles et al., 1980), porém não será abordado aqui.

Exemplos: Notas de aula.

2.5 Testes de hipóteses de aleatoriedade

O objetivo aqui é testar se uma séries de eventos é aleatória ou não. Relembre que nas disciplinas de Inferência Não-Paramétrica sempre supomos que $\underset{\sim}{\mathbf{X}}$: $X_1, ..., X_n$ é uma amostra aleatória. Desejamos testar

$$H_0 : \text{A amostra } \underset{\sim}{\mathbf{X}} \text{ é aleatória} \quad \times \quad H_1 : \text{A amostra } \underset{\sim}{\mathbf{X}} \text{ não é aleatória}$$

Ao passar por uma fila de entrada para um cinema (ou INSS, entre outras), a sequência formada por homens e mulheres seria aleatória? Suponha que nessa fila tenham 10 pessoas, 5 homens (H) e 5 mulheres (M). Existem 252 maneiras/configurações possíveis (permutação com elementos repetidos). Dois extremos de configuração são:

$$\text{HHHHHMMMMM ou HMHMHMHMHM,}$$

indicando não haver aleatoriedade. Na verdade, pensando em um experimento de lançamento de uma moeda n vezes, dado que ocorreram n_1 caras e n_2 coroas, $n_1 + n_2 = n$, temos $\frac{n!}{n_1! n_2!}$ (permutação com elementos repetidos) configurações possíveis.

Podemos construir variáveis aleatórias a partir deste experimento para desenvolver testes de aleatoriedade.

2.5.1 Testes de corridas

Definição 11. *Dada uma sequência ordenada de um ou mais tipos de símbolos, uma corrida é definida ser uma sucessão de um mesmo símbolo, que é seguida por um símbolo diferente.*

No caso dos exemplos na introdução da Seção, teríamos em HHHHH MMMMM 2 corridas e em HMHMHMHMHM 10 corridas. Se o resultado fosse HHMMMHMMHH, teríamos 5 corridas.

Para variáveis binárias, calculamos o número de objetos do tipo 1, do tipo 2 e o número de corridas.

Para uma amostra aleatória $X_1, ..., X_n$ de variáveis quantitativas, Gibbons and Chakraborti (2003) sugerem comparar as observações com um ponto focal, geralmente a média ou mediana. Assim, sendo $M = \overline{X}$ ou $M = \widetilde{X}$, teremos

$$Y_i = \begin{cases} +, & \text{se } X_i > M, \\ -, & \text{se } X_i < M, \ i = 1, 2, ..., n. \end{cases}$$

Se houver empate, isto é, $X_{i+1} = M$, descarte e atualize n. Para variáveis contínuas, temos que $P(X_{i+1} = X_i) = 0$.

Assim, dado um número de n símbolos, n_1 objetos do tipo 1 (H, por exemplo) e n_2 objetos do tipo 2 (M, por exemplo), $n_1 + n_2 = n$, defina R como o *número de corridas*. Se tivermos um número de corridas próximo do $m\acute{i}nimo(R) = 2$ ou próximo do $máximo(R) = n$, temos indícios de não-aleatoriedade (rejeição de H_0). Valores medianos do número de corridas são favoráveis à aceitação da hipótese nula.

Para derivar um teste de aleatoriedade baseado no número de corridas R, precisamos construir a distribuição de probabilidade de R sob a hipótese nula.

Sejam r_1 o número de corridas do tipo 1 e r_2 o tipo de corridas do tipo 2, $r = r_1 + r_2$ o total de corridas. Assim, $R = R_1 + R_2$.

Temos que $P(R_1 = r_1, R_2 = r_2)$ é o número de arranjos distinguíveis com r_1 do tipo 1 e r_2 do tipo 2, dividido pelo total de arranjos distinguíveis, dado por $\frac{n!}{n_1! n_2!}$.

A seguir apresentamos resultados das distribuições conjunta e marginal ((R_1, R_2) e R_1) bem como a distribuição de R e seus momentos. As provas podem ser vistas em Gibbons and Chakraborti (2003).

Teorema 9. *Sejam R_1 e R_2 os respectivos números de corridas de n_1 objetos do tipo 1 e n_2 objetos do tipo 2, respectivamente em uma amostra aleatória de tamanho $n = n_1 + n_2$. A distribuição de probabilidade conjunta de R_1 e R_2 é dada por*

$$f_{R_1,R_2}(r_1, r_2) = \frac{c \begin{pmatrix} n_1 - 1 \\ r_1 - 1 \end{pmatrix} \begin{pmatrix} n_2 - 1 \\ r_2 - 1 \end{pmatrix}}{\begin{pmatrix} n \\ n_1 \end{pmatrix}}, \qquad \begin{matrix} r_1 = 1, 2, ..., n_1 \\ r_2 = 1, 2, ..., n_2 \\ r_1 = r_2 \ ou \ r_2 = \pm 1, \end{matrix} \tag{9}$$

onde $c = 2$ se $r_1 = r_2$ ou $c = 1$ se $r_1 = r_2 \pm 1$.

Corolário 3. *A distribuição marginal de R_1 é dada por*

$$f_{R_1}(r_1) = \frac{\binom{n_1 - 1}{r_1 - 1}\binom{n_2 + 1}{r_1}}{\binom{n}{n_1}}, \quad r_1 = 1, 2, ..., n_1. \tag{10}$$

A distribuição de R_2 é similar intercambiando n_1 e n_2.

Teorema 10. *A distribuição de probabilidade de R é dada por*

$$f_R(r) = \tag{11}$$
$$\begin{cases} 2\dfrac{\binom{n_1 - 1}{r/2 - 1}\binom{n_2 - 1}{r/2 - 1}}{\binom{n}{n_1}}, & \text{se } r \text{ é par,} \\ \dfrac{\binom{n_1 - 1}{(r-1)/2}\binom{n_2 - 1}{(r-3)/2} + \binom{n_1 - 1}{(r-3)/2}\binom{n_2 - 1}{(r-1)/2}}{\binom{n}{n_1}}, & \text{se } r \text{ é ímpar,} \end{cases}$$

para $r = 2, 3, ..., n$.

O valor esperado e a variância de R são dados por

$$E(R) = 1 + \frac{2n_1n_2}{n} \quad \text{e} \quad Var(R) = \frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}.$$

Embora tenhamos a distribuição exata, os cálculos computacionais para grandes amostras podem ser demorados. Assim, podemos usar a distribuição assintótica de R,

$$Z = \frac{R - E(R)}{\sqrt{Var(R)}} \overset{\text{a}}{\sim} N(0, 1).$$

Como a variável aleatória R é discreta, utilizamos uma *correção de continuidade*, que é subtrair 0.5 no numerador de Z quando este for positivo ou adicionar a mesma quantidade quando o numerador for negativo. Desta forma, estamos reduzindo o valor da estatística Z, "favorecendo" a hipótese nula (ou reduzindo a probabilidade do erro tipo I). Assim, temos

$$Z_c = \frac{R - E(R) - 0.5 * sign(R - E(R))}{\sqrt{Var(R)}} \overset{\text{a}}{\sim} N(0,1).$$

No R: runs.test{snpar}

Observação: São fornecidas funções no R (R Core Team, 2019) para o número de corridas R para variáveis Bernoulli's ou numéricas, além da função de probabilidade, função distribuição acumulada e quantis de R (Notas de aula).

Gibbons and Chakraborti (2003, Seção 3.2) apresentam um teste de aleatoriedade baseado no comprimento da corrida mais longa. Outro método conhecido é o chamado *runs up and down test* (Gibbons and Chakraborti, 2003, Seção 3.4), considerando as diferenças entre observações sucessivas.

$$Y_i = \begin{cases} +, & \text{se } X_{i+1} > X_i, \\ -, & \text{se } X_{i+1} < X_i, \ i = 1, 2, ..., n-1. \end{cases}$$

2.5.2 Teste de aleatoriedade de Bartels

Esta estatística de teste é construída utilizando os postos da amostra $\underset{\sim}{\mathbf{X}}$: $X_1, ..., X_n$. Porém, somente pode ser aplicada para variáveis numéricas. Bartels (1982) adapta a estatística de "Von Neumann's Ratio" para testar aleatoriedade.

Definição 12. *Dada uma amostra $X_1, ..., X_n$, o posto de uma observação X_i, denotado por R_i, é a posição (ascendente) que X_i ocupa na amostra.*

Dada uma amostra $X_1, ..., X_n$, Bartels (1982) propõe a estatística

$$NM = \sum_{i=1}^{n-1} \left[R_i - R_{i+1}\right]^2. \tag{12}$$

Temos que

$$\begin{cases} n - 1 < NM < (n-1)(N^2 + n - 3)/3, & \text{se } n \text{ é par}, \\ n - 1 < NM < (n-1)(N^2 + n - 3)/3 - 1, & \text{se } n \text{ é ímpar}. \end{cases}$$

A distribuição exata de NM não tem expressão fechada. Bartels (1982) apresenta uma tabela com valores críticos da estatística, para $4 \leq n \leq 10$. Para grandes amostras, trabalha-se com a razão RVN dada por

$$RVN = \frac{\sum_{i=1}^{n-1} (R_i - R_{i+1})^2}{\sum_{i=1}^{n} \left(R_i - \overline{R}\right)^2} \overset{\text{a}}{\sim} N(2, \sigma_n^2),$$

onde $\sigma_n^2 = \frac{4(n-2)(5n^2-2n-9)}{5n(n+1)(n-1)^2} \approx \frac{20}{5n+7} \approx 4/n$.

Caso não existam empates, o denominador de RVN é dado por $n(n^2 - 1)/12$.

No R: bartels.test{lawstat}.

Sheskin (2000), Unidade 10, apresenta outros testes de aleatoriedade.

Exemplos: Notas de aula.

2.5.3 Possíveis casos de não-aleatoriedade

Dois modelos interessantes que poderiam levar à rejeição da hipótese de aleatoriedade são: Ponto de mudança e tendência. Apresentamos nesta seção os testes do ponto de mudança e de tendência de Cox-Stuart.

i) Teste de ponto de mudança

Dada uma amostra $\underset{\sim}{\mathbf{X}} : X_1, ..., X_N$ (por exemplo, Figura 6), desejamos testar

$$\begin{array}{l} H_0 : \text{Não há mudança abrupta na sequência dos dados} \\ H_1 : \text{Há mudança abrupta na sequência dos dados.} \end{array} \tag{13}$$

Trataremos dois casos: o primeiro quando a variável é tipo $0-1$ e um segundo para variáveis contínuas.

No primeiro caso, vamos supor que $X \sim Bernoulli(p)$. Adaptamos as hipóteses do teste como

H_0 : Não há mudança abrupta na probabilidade de sucessos ao longo do "tempo".
H_1 : Há mudança abrupta na probabilidade de sucessos ao longo do "tempo".

A estatística de teste é dada por

$$D_{m,n} = \frac{N}{mn} \underset{1 \leq \text{j} \leq \text{N}-1}{max} \left| S_j - \frac{jm}{N} \right|, \tag{14}$$

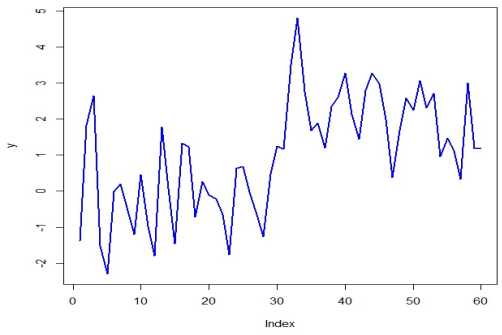


Figura 6: Ponto de mudança.

onde $m = \sum_{i=1}^{N} X_i$ (número de "sucessos"), $n = N - m$ (número de "fracassos") e $S_j = \sum_{i=1}^{j} X_i$ (número de "sucessos" até o instante j). Os valores críticos de $D_{m,n}$ são encontrados na Tabela L_{II} para pequenas amostras ou na Tabela L_{III} para grandes amostras (Siegel and Castellan, Jr., 2006).

Observação: A posição em que ocorre o máximo em $D_{m,n}$ é o ponto de mudança.

Para variáveis contínuas, a estatística de teste é baseada nos postos R_i, $i = 1, ..., n$. Seja $W_j = \sum_{i=1}^{j} R_i$. As hipóteses são as mesmas de (13).

Estatística de teste:

$$K_{m,n} = \max_{1 \leq j \leq N-1} \left|2W_j - j(N+1)\right| = 2 \max_{1 \leq j \leq N-1} \left|W_j - j(N+1)/2\right|. \quad (15)$$

Os valores críticos da estatística $K_{m,n}$ são dados na Tabela J (Siegel and Castellan, Jr., 2006).

Observação: $S_N = \sum_{i=1}^{N} R_i$, então $S_N = N(N+1)/2$.

A posição em que ocorre o máximo em $K_{m,n}$, neste caso m, é o ponto de mudança.

Para grandes amostras, seja m o ponto de mudança e W_m a soma dos postos de $X_1, X_2, ..., X_m$. Tem-se que $E(W_m) = m(N+1)/2$ e $Var(W_m) = mn(N+1)/12$. Como W_m é uma variável aleatória discreta, para grandes amostras, utilizamos a aproximação pela Normal com correção de continuidade, Para grandes amostras, trabalha-se com a razão RVN dada por

$$Z = \frac{W - E(W_m) - 0.5 * sign(W - E(W_m))}{\sqrt{(Var(W_m))}} \overset{a}{\sim} N(0,1).$$

Exemplos: Notas de aula.

ii) Teste de tendência de Cox-Stuart

Dada uma amostra $\underset{\sim}{\mathbf{X}} : X_1, ..., X_{n'}$, considerando que as observações são independentes, em uma escala pelo menos ordinal, desejamos testar se existe uma tendência (crescente ou decrescente) na sequência. Considere os pares $(X_1, X_{1+c}),\ (X_2, X_{2+c}), ..., (X_{n'-c}, X_{n'})$, onde $c = n'/2$ se n' é par ou $c = (n'+1)/2$ se n' é ímpar. Note que, para n' ímpar, descartamos a observação $X_{(n'+1)/2}$.

Seja a variável Y como

$$Y_j = \begin{cases} +, & \text{se } X_{j+c} > X_j, \\ -, & \text{se } X_{j+c} < X_j, \ j = 1, 2, ..., c. \end{cases}$$

Se $X_{j+c} = X_j$, descarte a observação. Seja n o número final de observações de Y. Sob H_0, $Y \sim Binomial(n, 1/2)$. Utilizamos Y como a estatística de teste para testar se há tendência ou não nos dados.

Observação: Conover (1999) aponta que o teste de tendência de Cox-Stuart é uma variação do teste do Sinal, que será abordado na Seção 3.

No R: cox.stuart.test{randtests}.

Exemplos: Notas de aula.

Lista de exercícios 2.5.

- *Conover (1999), Cap. 3, pág. 176-177: 3-8.*
- *Sprent and Smeeton (2007), Cap. 4: 8 a 12.*
- *Gibbons and Chakraborti (2003), Cap. 3: 14, 15, 18.*